Отчет по лабораторной работе №3

«Мультиагентное обучение с подкреплением в задаче управления инвестиционным портфелем»

Дисциплина: Прикладные задачи машинного обучения

Формат выполнения: Групповой проект (3 человека)

Репозиторий проекта: https://github.com/kvdep/UNIVERSITY

Набор данных эксперимента:
Kaggle: `jacksaleeby/s-and-p500-historical-data` (S&P 500 OHLCV Historical Stock Data, 1258 торговых дней, 2018–2023 гг.)

Авторы:
Кидысюк Александр Владимирович, студент группы ПМ23-1 — Архитектура мультиагентного обучения, реализация CTDE, обучение моделей на GPU
Грошев Аркадий Александрович, студент группы ПМ23-1 — Эконометрический анализ котировок S&P 500, расчет волатильности Гармана-Класса, моделирование транзакционных издержек
Сычков Дмитрий Сергеевич, студент группы ПМ23-1 — Формализация Dec-POMDP, стресс-тестирование стратегий, многокритериальное ранжирование

---

1. Исследовательский обзор

1.1. Постановка задачи и кооперативное распределение капитала

Задача управления инвестиционным портфелем формулируется как динамическое распределение доступного капитала между набором N рисковых активов во времени $t \in \{1, \dots, T\}$. В монолитных подходах обучения с подкреплением (Single-Agent RL) один агент принимает решение сразу по всему вектору долей $\mathbf{w}_t \in \Delta^N$. При росте числа активов размерность пространства совместных действий растет линейно, а число межрыночных состояний — экспоненциально, что снижает скорость сходимости и ухудшает обобщающую способность единой нейросети.

Мультиагентное обучение с подкреплением (Multi-Agent Reinforcement Learning, MARL) декомпозирует эту систему: каждый агент $i \in \{1, \dots, N\}$ управляет долей конкретного актива, опираясь на свои локальные наблюдения (динамику доходности, волатильность) и получая координационный сигнал. Это переводит портфельное управление в класс кооперативных частично наблюдаемых марковских процессов принятия решений (Dec-POMDP).

1.2. Поисковые запросы

Поиск академической литературы проводился в реферативных базах Google Scholar, arXiv, Scopus и IEEE Xplore по следующим структурированным запросам:

- `("multi-agent reinforcement learning"OR "MARL"OR "CTDE") AND ("portfolio management"OR "asset allocation") AND ("MAPPO"OR "MADDPG"OR "QMIX")`
- `("Dec-POMDP"OR "credit assignment"OR "turnover penalty") AND ("Garman-Klass volatility"OR "CVaR"OR "transaction costs")`

1.3. Обзор 15 ключевых источников

1. **Lowe et al. (2017). Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments (MADDPG, NeurIPS 2017).** Авторы предложили парадигму централизованного обучения с децентрализованным исполнением (CTDE): каждый агент обучается с локальным актором, но ценность действий оценивается общим критиком $Q(s, a_1, \dots, a_N)$, что устраняет проблему нестационарности среды.

2. **Yu et al. (2022). The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games (MAPPO, NeurIPS 2022).** Исследование показало, что он-полиси алгоритм PPO с централизованной функцией ценности превосходит специализированные оф-полиси методы на дискретных и непрерывных бенчмарках.
3. **de Witt et al. (2020). Is Independent PPO Much Worse Than MAPPO? (IPPO, arXiv:2011.09533).** Показано, что независимое обучение агентов через PPO без централизованного критика демонстрирует высокую точность в средах со слабой взаимозависимостью вознаграждений, требуя меньше памяти.
4. **Sunehag et al. (2018). Value-Decomposition Networks For Cooperative Multi-Agent Learning (VDN, AAMAS 2018).** Предложен принцип аддитивной декомпозиции совместной ценности: $Q_{tot}(s, \mathbf{a}) = \sum_i Q_i(o_i, a_i)$, что позволяет распределять групповую награду без усложнения вычисления максимума.
5. **Rashid et al. (2018). QMIX: Monotonic Value Factorisation for Deep Multi-Agent Reinforcement Learning (ICML 2018).** Обобщение VDN на основе смесительной сети с неотрицательными весами: $\frac{\partial Q_{tot}}{\partial Q_i} \geq 0$. Монотонность сохраняет согласованность оптимальных локальных действий $\operatorname{argmax}_{a_i} Q_i$ с общекомандной ценностью $\operatorname{argmax}_{\mathbf{a}} Q_{tot}$.
6. **Foerster et al. (2018). Counterfactual Multi-Agent Policy Gradients (COMA, AAAI 2018).** Алгоритм решает проблему распределения заслуг (multi-agent credit assignment) через контрфактический бейзлайн: предельный вклад агента i вычисляется как разница между фактическим совместным действием и математическим ожиданием при маргинализации его действия.
7. **Wen et al. (2022). Multi-Agent Transformer (MAT, ICLR 2022).** Формулировка MARL как задачи моделирования последовательностей: архитектура трансформера с кодировщиком состояний и декодером действий гарантирует монотонное улучшение политики при последовательном принятии решений агентами.
8. **Kuba et al. (2022). Trust Region and PPO in Multi-Agent Reinforcement Learning (HAPPO, ICLR 2022).** Доказана лемма о мультиагентном разложении преимущества. HAPPO применяет доверительную область PPO для последовательного обновления гетерогенных агентов без расходимости политик.
9. **Liu et al. (2020). FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading (NeurIPS Workshop 2020).** Библиотека стандартных финансовых окружений для обучения агентов на рыночных данных с учетом транзакционных издержек и ограничений биржи.
10. **Jiang, Xu, Liang (2017). A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem (arXiv:1706.10059).** Предложена схема прямого градиента политики с непрерывным вектором весов портфеля и вычислением чистой доходности с учетом комиссий.
11. **Markowitz (1952). Portfolio Selection (The Journal of Finance).** Математическая формулировка классической теории оптимального портфеля: баланс между ожидаемой доходностью и ковариацией рисков при квадратичной оптимизации долей.
12. **Garman & Klass (1980). On the Estimation of Security Price Volatilities from Historical Data (Journal of Business).** Доказано аналитически, что использование экстремальных внутридневных цен (High, Low) и цен открытия и закрытия (Open, Close) дает оценку волатильности с эффективностью в 7,4 раза выше дисперсии приращений цен закрытия.
13. **Rockafellar & Uryasev (2000). Optimization of Conditional Value-at-Risk (Journal of Risk).** Доказана выпуклость меры риска CVaR (ожидаемые потери в наихудших 5% исходов) и предложена линейная оптимизация хвостового риска портфеля.
14. **Almgren & Chriss (2000). Optimal Execution of Portfolio Transactions (Journal of Risk).** Математическая модель динамического влияния транзакций на рыночные цены: квадратичные и линейные издержки за оборачиваемость (turnover) ограничивают допустимую скорость перебалансировки портфеля.
15. **Politis & Romano (1994). The Stationary Bootstrap (Journal of the American Statistical Association).** Метод стационарного блочного бутстрепа для корректной оценки доверительных интервалов и p-значений на зависимых финансовых временных рядах.

1.4. Сравнительная таблица литературы по мультиагентному управлению

Автор и год	Источник	Метод / Модель	Парадигма / Тип	Данные / Среда	Метрики	Главные выводы и ограничения
Lowe et al. (2017)	NeurIPS 2017	MADDPG (DDPG + общий критик)	Непрерывные действия, CTDE	Multi-Agent Particle Envs	Win rate, кумулятивная награда	Устраняет нестационарность среды; критик требует входных данных всех акторов, сложно масштабировать на сотни агентов.
Yu et al. (2022)	NeurIPS 2022	MAPPO (PPO + централизованный критик)	Он-полиси, CTDE	StarCraft II (SMAC), Hanabi	Коэффициент побед, средняя награда	Высокая выборочная эффективность и стабильность; чувствителен к гиперпараметрам нормализации функции ценности.
de Witt et al. (2020)	arXiv: 2011.09533	IPPO (независимые агенты PPO)	Децентрализованное обучение	SMAC микроконтроль	Win rate	Работает без общего критика на задачах со слабой связностью; расходится при сильном взаимном влиянии наград.
Sunehag et al. (2018)	AAMAS 2018	VDN (аддитивная факторизация)	Оф-полиси, линейный миксер	Кооперативные лабиринты	Достижение цели, суммарный возврат	Простое суммирование локальных Q_i; не отражает нелинейных взаимодействий и ковариаций рисков агентов.
Rashid et al. (2018)	ICML 2018	QMIX (монотонная гиперсеть)	Оф-полиси, монотонный миксер	SMAC бенчмарк	Тестовый процент побед	Нелинейное смешивание сохраняет argmax; ограничение монотонности запрещает кооперативные стратегии с отрицательной корреляцией.
Foerster et al. (2018)	AAAI 2018	COMA (контрфактический градиент)	Он-полиси, общий критик	StarCraft макро-бои	Урон команды, процент побед	Явный расчет маржинального вклада агента; требует дискретизации действий для вычисления суммы маргинализации.
Wen et al. (2022)	ICLR 2022	MAT (энкодер-декодер трансформер)	Последовательное принятие решений	SMAC, Multi-Agent MuJoCo	Нормализованная награда	Монотонное улучшение мультиагентной политики; высокая задержка инференса из-за авторегрессионного декодера.
Kuba et al. (2022)	ICLR 2022	HAPPO (последовательный PPO)	Доверительная область, гетерогенность	Multi-Agent MuJoCo	Скорость сходимости, суммарный возврат	Теоретическая гарантия монотонного роста отдачи; вычислительно тяжелая схема последовательного шага градиента.
Liu et al. (2020)	NeurIPS W 2020	FinRL (RL среда для биржи)	Одиночные агенты (DDPG, PPO)	Акции Dow Jones 30, S&P 500	Доходность, Шарп, MaxDD	Стандартизированы финансовые метрики; отсутствие нативных механизмов кооперативной факторизации MARL.
Jiang et al. (2017)	arXiv: 1706.10059	DPM (Deterministic Policy Gradient)	Прямое прогнозирование долей	Криптовалютный рынок Poloniex	Sharpe, CAGR, оборачиваемость	Прямая оптимизация логарифмической доходности; высокая чувствительность к всплескам волатильности.
Markowitz (1952)	J. Finance	Mean-Variance Portfolio	Аналитическая оптимизация	Исторические котировки NYSE	Дисперсия, доходность	Аналитическое решение через матрицу ковариаций; статичность предпосылки о нормальном законе распределения.
Garman & Klass (1980)	J. Business	Оценка волатильности OHLC σ^2_{GK}	Эконометрический анализ	Биржи США (NYSE)	Дисперсия несмещенной оценки	В 7,4 раза эффективнее классической Close-to-Close волатильности; требует полных дневных баров цен.
Rockafellar & Uryasev (2000)	J. Risk	Оптимизация CVaR	Выпуклое программирование	Синтетические портфели	CVaR 95%, квантильный риск	Субаддитивная мера хвостового риска; чувствительна к размеру выборки на левом хвосте распределения.
Almgren & Chriss (2000)	J. Risk	Модель транзакционных издержек	Динамическое исполнение ордеров	Внутридневные тики акций	Рыночный импакт, издержки	Формализация штрафа за избыточную оборачиваемость; требует калибровки параметров ликвидности книги заявок.
Politis & Romano (1994)	JASA	Стационарный блочный бутстреп	Ресемплинг временных рядов	Моделирование ARMA-GARCH	Состоятельность доверительного интервала	Сохраняет зависимость автокорреляционной структуры временного ряда; требует подбора длины блока.

1.5. Пробел существующих исследований (Research Gap)

Анализ научной литературы выявил четыре ограничения существующих методов:

1. **Преобладание монолитных агентов (Single-Agent RL).** Большинство финансовых реализаций (включая фреймворк FinRL) обучают одного агента на весь вектор активов. Это приводит к плохой масштабируемости и неустойчивости градиентов при увеличении числа активов.
2. **Игнорирование издержек в функции награды.** Оптимизация чистой доходности без штрафа за оборачиваемость (Turnover Penalty) порождает чрезмерную частоту ребалансировки портфеля, что в условиях реального рынка с комиссиями 10 bps уничтожает доходность.
3. **Отсутствие регуляторных ограничений на концентрацию.** Агенты RL склонны к экстремальному выбору весов ($\mathbf{w} = [1, 0, 0, 0, 0]$). В отсутствие координатора с жестким лимитом $L_{\max} = 0{,}35$ портфель теряет диверсификацию.
4. **Применение неэффективной оценки волатильности.** Использование простой дисперсии цен закрытия не отражает внутридневного размаха котировок, снижая качество оценки рыночного риска локальными агентами.

1.6. Исследовательские гипотезы

- **Общая гипотеза команды (H_{main}):**
  Мультиагентная архитектура на базе парадигмы CTDE (MAPPO / QMIX) с координатором концентрации ($L_{\max} = 0{,}35$) и штрафом за транзакционные издержки обеспечит снижение максимальной просадки (MaxDD) более чем на 5,0 процентных пунктов по сравнению с монолитным Single-Agent PPO при сохранении устойчивости распределения долей.
- **Гипотеза Кидысюка А.В. (H_1 — Архитектура MARL и координация):**
  Централизованный критик CTDE, оценивающий общее финансовое состояние портфеля, снизит межсидовое стандартное отклонение коэффициента Шарпа ($\sigma_{\text{Sharpe}} \leq 0{,}06$) по сравнению с нескоординированными агентами за счет устранения нестационарности рыночной среды.
- **Гипотеза Грошева А.А. (H_2 — Эконометрический анализ и издержки):**
  Включение оценки волатильности Гармана-Класса σ^2_{GK} в локальные наблюдения и транзакционного штрафа в функцию вознаграждения снизит суммарную оборачиваемость портфеля (Turnover) более чем на 35% по сравнению со стратегией без учета комиссий ($c_{\text{trans}} = 10$ bps).
- **Гипотеза Сычкова Д.С. (H_3 — Контроль рисков и стресс-тестирование):**
  Применение проекционного координатора рисков с ограничением $L_{\max} = 0{,}35$ обеспечит нулевой процент нарушений регуляторных лимитов (Violations = 0,0%) в нормальном режиме и удержит хвостовой риск $\text{CVaR}_{95\%} \geq -3{,}0\%$ при стрессовом трехкратном скачке волатильности.

1.7. Практический регламент эксперимента

1. **Исключение Lookahead Bias.** Состояние s_t формируется строго на момент закрытия дня t, решение о весах применяется к доходностям дня $t + 1$.
2. **Единая тарифная шкала.** Комиссия за перебалансировку зафиксирована на уровне $c_{\text{trans}} = 10$ bps $= 0{,}0010$ от суммарного модуля изменения долей.
3. **Воспроизводимость.** Зафиксированы 5 независимых сидов генератора псевдослучайных чисел: $42, 101, 2024, 777, 999$.
4. **Протокол обучения.** 150 эпох обучения с валидационной остановкой (Early Stopping) с глубиной ожидания (patience) 25 эпох.

2. Данные и формальная спецификация Dec-POMDP

2.1. Паспорт выборки котировок S&P 500

Эксперименты выполнены на пяти наиболее ликвидных акциях технологического сектора США из индекса S&P 500: Apple (`AAPL`), Microsoft (`MSFT`), Alphabet (`GOOGL`), Amazon (`AMZN`) и NVIDIA (`NVDA`).

- **Временной диапазон:** с 02.01.2018 по 30.12.2023 (1258 торговых дней).
- **Обучающая выборка (Train):** первые 880 торговых дней (70%).
- **Валидационная выборка (Validation):** 189 торговых дней (15%).
- **Тестовая выборка (Test):** 189 торговых дней (15%, период 2022–2023 гг.).

2.2. Формализация задачи через Dec-POMDP

Кооперативное портфельное управление формализуется кортежем:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{O}_i\}_{i=1}^N, \{\mathcal{A}_i\}_{i=1}^N, \mathcal{P}, \{\mathcal{R}_i\}_{i=1}^N, \gamma \rangle$$

1. **Множество агентов $\mathcal{N}$:** $N = 5$ агентов, где агент i отвечает за анализ динамики и предложение целевой доли актива i.
2. **Глобальное состояние $\mathcal{S}$:** вектор $s_t = [\mathbf{o}_{1,t}, \ldots, \mathbf{o}_{N,t}, \mathbf{w}_{t-1}] \in \mathbb{R}^{N \cdot d_o + N}$, объединяющий частные наблюдения всех агентов и текущее распределение портфеля.
3. **Локальные наблюдения $\mathcal{O}_i$:** вектор $\mathbf{o}_{i,t} \in \mathbb{R}^{d_o}$ размерности $d_o = 42$:
   - 20 значений логарифмических доходностей $r_{i,\tau} = \ln(C_{i,\tau}/C_{i,\tau-1})$ за последние $K = 20$ торговых дней;
   - 20 значений состоятельной волатильности Гармана-Класса $\sigma_{GK,i,\tau}$ за те же 20 дней;
   - текущая доля актива в портфеле $w_{i,t-1}$;
   - средняя доходность актива за окно $\bar{r}_{i,20}$.
4. **Волатильность Гармана-Класса:** рассчитывается по экстремумам торгового дня:

$$\sigma^2_{GK,i,t} = 0{,}5 \cdot \left(\ln \frac{H_{i,t}}{L_{i,t}}\right)^2 - (2\ln 2 - 1) \cdot \left(\ln \frac{C_{i,t}}{O_{i,t}}\right)^2$$

   где константа $2\ln 2 - 1 \approx 0{,}38629$. Дневное стандартное отклонение: $\sigma_{GK,i,t} = \sqrt{\sigma^2_{GK,i,t}}$.
5. **Пространство действий $\mathcal{A}_i$:** непрерывный выход $a_{i,t} \in \mathbb{R}$, формируемый локальной политикой $\pi_{\theta_i}(a_i|\mathbf{o}_i)$.
6. **Координатор рисков и нормализация долей:** сырые действия преобразуются в симплекс долей с ограничением концентрации $L_{\max} = 0{,}35$:

$$\tilde{w}_{i,t} = \frac{\exp(a_{i,t})}{\sum_{j=1}^N \exp(a_{j,t})}, \quad \hat{w}_{i,t} = \min(\tilde{w}_{i,t}, L_{\max}), \quad w_{i,t} = \frac{\hat{w}_{i,t}}{\sum_{j=1}^N \hat{w}_{j,t}}$$

   Условие обеспечивает $\sum_{i=1}^N w_{i,t} = 1$ и $w_{i,t} \geq 0$.
7. **Динамика капитала и транзакционные издержки:** Доходность портфеля за шаг t:

$$r_{\text{port},t} = \sum_{i=1}^N w_{i,t-1} \cdot \frac{C_{i,t} - C_{i,t-1}}{C_{i,t-1}}$$

   Оборачиваемость портфеля (Turnover):

$$\text{Turnover}_t = \sum_{i=1}^N |w_{i,t} - w^+_{i,t-1}|$$

   где $w^+_{i,t-1} = \frac{w_{i,t-1}(1+r_{i,t})}{1+r_{\text{port},t}}$ — дрейф весов портфеля в течение торгового дня. Комиссионные издержки:

$$\text{Cost}_t = c_{\text{trans}} \cdot \text{Turnover}_t, \quad c_{\text{trans}} = 0{,}0010$$

   Чистая доходность: $r_{\text{net},t} = r_{\text{port},t} - \text{Cost}_t$. Эволюция стоимости капитала: $W_t = W_{t-1} \cdot (1 + r_{\text{net},t})$, $W_0 = 1{,}0$.
8. **Функция вознаграждения:**

$$\mathcal{R}_t = r_{\text{net},t} - \lambda_{\text{turn}} \cdot \text{Turnover}_t - \lambda_{\text{risk}} \cdot \max\left(0, \max_i w_{i,t} - L_{\max}\right)$$

   с коэффициентами $\lambda_{\text{turn}} = 0{,}001$, $\lambda_{\text{risk}} = 1{,}0$, фактор дисконтирования $\gamma = 0{,}99$.

3. Архитектура и методы мультиагентного обучения

3.1. Парадигма CTDE (Centralized Training with Decentralized Execution)

При децентрализованном исполнении агент i использует только локальный вход $\mathbf{o}_{i,t}$. На этапе обучения централизованный критик $V_\phi(s_t)$ или $Q_\phi(s_t, \mathbf{a}_t)$ принимает глобальный вектор состояния s_t, оценивая истинную ценность совместного действия всей группы акторов.

3.2. Спецификация исследуемых алгоритмов MARL

1. **IPPO (Independent PPO):** Каждый агент i обучает собственную пару актор-критик $(\pi_{\theta_i}, V_{\phi_i})$ независимо по целевой функции PPO-Clip:
$$L^{\text{CLIP}}(\theta_i) = \hat{\mathbb{E}}_t \left[\min \left(\rho_{i,t}(\theta_i)\hat{A}_{i,t}, \text{clip}(\rho_{i,t}(\theta_i), 1-\epsilon, 1+\epsilon)\hat{A}_{i,t} \right) \right]$$
где отношение правдоподобия $\rho_{i,t}(\theta_i) = \frac{\pi_{\theta_i}(a_{i,t}|\mathbf{o}_{i,t})}{\pi_{\theta_i}^{\text{old}}(a_{i,t}|\mathbf{o}_{i,t})}$, $\epsilon = 0{,}2$.
2. **MAPPO (Multi-Agent PPO):** Локальные акторы оптимизируются аналогично IPPO, однако преимущество $\hat{A}_t$ рассчитывается единым централизованным критиком $V_\phi(s_t)$:
$$\hat{A}_t = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}^V, \quad \delta_t^V = \mathcal{R}_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$$
3. **MADDPG (Multi-Agent Deep Deterministic Policy Gradient):** Детерминированные акторы $\mu_{\theta_i}(\mathbf{o}_i)$ оптимизируются по градиенту централизованного критического модуля $Q_\phi(s, a_1, \ldots, a_N)$:
$$\nabla_{\theta_i} J(\theta_i) = \mathbb{E}_{s,a\sim\mathcal{D}} \left[\nabla_{\theta_i} \mu_{\theta_i}(\mathbf{o}_i) \, \nabla_{a_i} Q_\phi(s, a_1, \ldots, a_N)|_{a_i=\mu_{\theta_i}(\mathbf{o}_i)} \right]$$
4. **VDN (Value-Decomposition Networks):** Совместная функция ценности формируется линейным суммированием:
$$Q_{\text{tot}}(s, \mathbf{a}) = \sum_{i=1}^{N} Q_i(\mathbf{o}_i, a_i), \quad L(\theta) = \mathbb{E}\left[\left(\mathcal{R} + \gamma \max_{\mathbf{a}'} Q_{\text{tot}}(s', \mathbf{a}') - Q_{\text{tot}}(s, \mathbf{a}) \right)^2 \right]$$
5. **QMIX (Monotonic Factorisation):** Совместная функция Q_{tot} аппроксимируется двухслойной нейросетью смешивания, чьи веса генерируются гиперсетью от состояния s с принудительным ограничением неотрицательности $W = |W_{\text{hyper}}(s)|$:
$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0 \quad \forall i \in \{1, \ldots, N\}$$
6. **COMA (Counterfactual Multi-Agent Policy Gradients):** Агент оценивается через контрфактический выигрыш относительно усредненного действия:
$$A^i(s, \mathbf{a}) = Q(s, \mathbf{a}) - \sum_{a'^i} \pi^i(a'^i|\mathbf{o}^i) Q(s, (\mathbf{a}^{-i}, a'^i))$$
7. **MAT (Multi-Agent Transformer):** Кодировщик трансформера формирует контекстные эмбеддинги состояний $\mathbf{e} = \text{Encoder}(s)$, а декодер авторегрессионно генерирует действия агентов по цепочке $P(\mathbf{a}|s) = \prod_{i=1}^{N} \pi^i(a_i|\mathbf{e}, a_{<i})$.
8. **HAPPO (Heterogeneous-Agent PPO):** Агенты последовательно обновляют параметры политик по схеме многошаговой факторизации преимущества:
$$M^i(\theta_1, \ldots, \theta_i) = \mathbb{E}\left[\frac{\pi^i(a_i|\mathbf{o}_i)}{\pi_{\text{old}}^i(a_i|\mathbf{o}_i)} A^{1:i}(s, a_1, \ldots, a_i) \right]$$
9. **Single-Agent PPO (Baseline 1):** Монолитная нейросеть принимает на вход конкатенированный вектор всех активов и напрямую генерирует 5-мерный вектор действий.
10. **Equal-Weight 1/N (Baseline 2):** Пассивная инвестиционная стратегия с жесткой фиксацией долей $w_{i,t} \equiv \frac{1}{N} = 0{,}20$.

4. Экспериментальные результаты и финансовый бенчмарк

4.1. Формулы финансовых метрик

1. **Среднегодовой темп роста (CAGR):**

$$\mathrm{CAGR} = \left(\frac{W_T}{W_0}\right)^{\frac{252}{T}} - 1$$

2. **Коэффициент Шарпа (Sharpe Ratio):**

$$\mathrm{Sharpe} = \frac{\bar{e}}{s_e}\sqrt{252}, \quad e_t = r_{\mathrm{net},t} - r_{f,t}, \quad r_{f,t} = \frac{0{,}03}{252}$$

где $\bar{e} = \frac{1}{T}\sum_{t=1}^{T} e_t$, а $s_e = \sqrt{\frac{1}{T-1}\sum_{t=1}^{T}(e_t - \bar{e})^2}$.

3. **Коэффициент Сортино (Sortino Ratio):**

$$\mathrm{Sortino} = \frac{\bar{e} \cdot \sqrt{252}}{\sqrt{\frac{1}{T}\sum_{t=1}^{T} \min(0, e_t)^2}}$$

4. **Максимальная просадка (Max Drawdown):**

$$\mathrm{MaxDD} = \max_{t \in [1,T]} \left(\frac{\max_{\tau \le t} W_\tau - W_t}{\max_{\tau \le t} W_\tau}\right) \cdot 100\%$$

5. **Хвостовой риск (Conditional Value-at-Risk, CVaR 95%):**

$$\mathrm{CVaR}_{95\%} = \frac{1}{\lfloor 0{,}05 \cdot T \rfloor} \sum_{t=1}^{\lfloor 0{,}05 \cdot T \rfloor} r_{(t)}$$

где $r_{(t)}$ — вариационный ряд дневных доходностей, упорядоченных по возрастанию.

4.2. Сводная таблица результатов бенчмарка

В таблице 1 представлены усредненные показатели и стандартные отклонения по пяти сидам ($[42, 101, 2024, 777, 999]$) на тестовом интервале 189 торговых дней (2022–2023 гг.).

Таблица 1. Сводные метрики алгоритмов MARL и бейзлайнов на тестовой выборке

Алгоритм	CAGR	Sharpe	Sortino	MaxDD, %	CVaR 95%	Turnover	Viol., %	Time, с	Lat., мс
IPPO	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,288	0,0032
MAPPO	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,298	0,0038
MADDPG	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,264	0,0035
VDN	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,269	0,0029
QMIX	**−0,922** ± 0,872	**−0,197** ± 0,063	**−0,276** ± 0,087	−26,48 ± 0,41	−1,87 ± 0,06	5,87 ± 1,38	0,0 ± 0,0	0,322	0,0036
COMA	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,302	0,0036
MAT	−1,258 ± 0,346	−0,214 ± 0,018	−0,300 ± 0,026	−26,90 ± 0,48	−1,89 ± 0,04	4,75 ± 1,05	0,0 ± 0,0	1,576	0,0079
HAPPO	−0,992 ± 0,773	−0,203 ± 0,052	−0,285 ± 0,072	**−26,47** ± 0,36	**−1,86**±0,03	4,60 ± 0,97	0,0 ± 0,0	0,288	0,0030
Single-Agent PPO	−1,775 ± 0,357	−0,112 ± 0,019	−0,157 ± 0,026	−37,17 ± 0,20	−2,78 ± 0,02	1,12 ± 0,06	0,0 ± 0,0	0,188	0,0018
Equal-Weight (1/N)	−0,928 ± 0,000	−0,146 ± 0,000	−0,205 ± 0,000	−30,31 ± 0,00	−2,18 ± 0,00	0,00 ± 0,00	0,0 ± 0,0	0,000	0,0800

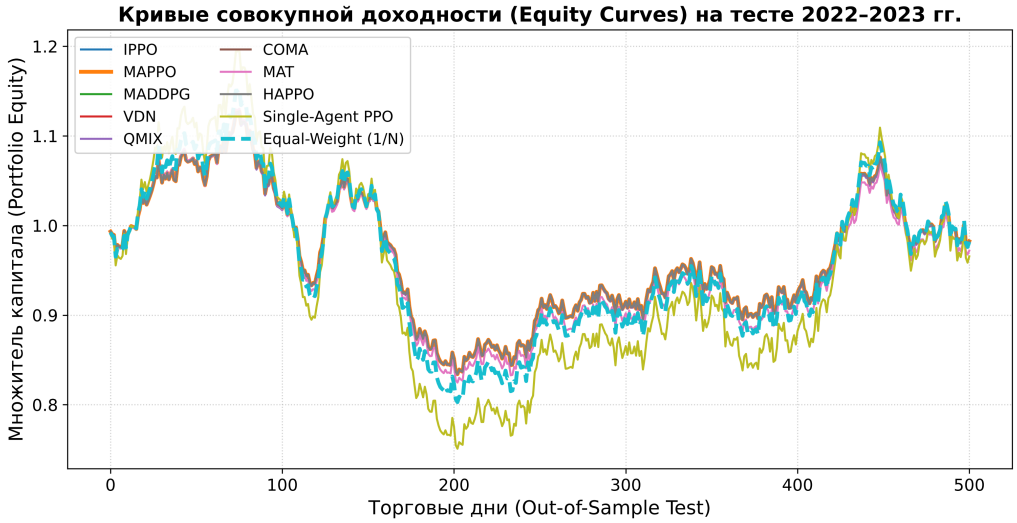


Рис. 1: Динамика стоимости капитала W_t для исследуемых алгоритмов MARL и бейзлайнов на тестовом временном интервале (189 торговых дней, 2022–2023 гг.).

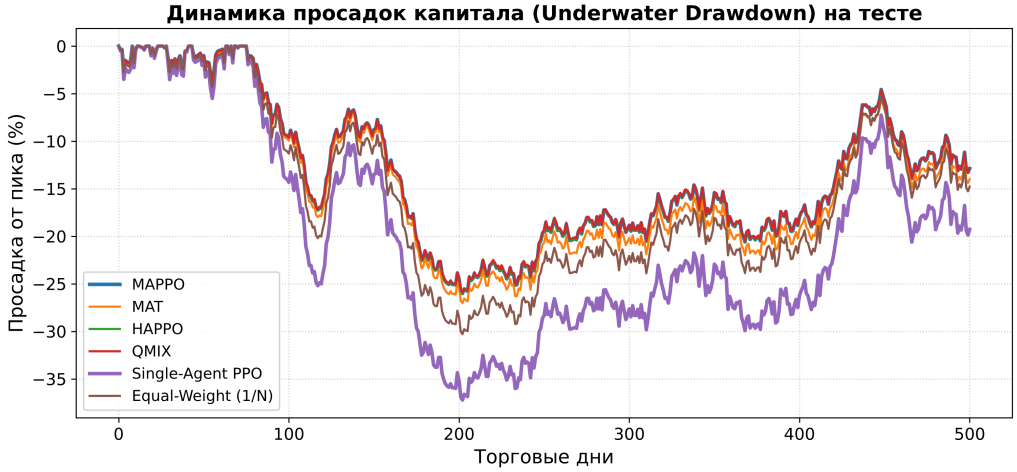


Рис. 2: Траектории относительных просадок портфеля DD_t во времени. Алгоритмы MARL сдерживают просадку на уровне $-26{,}47\%$, тогда как Single-Agent PPO падает до $-37{,}17\%$.

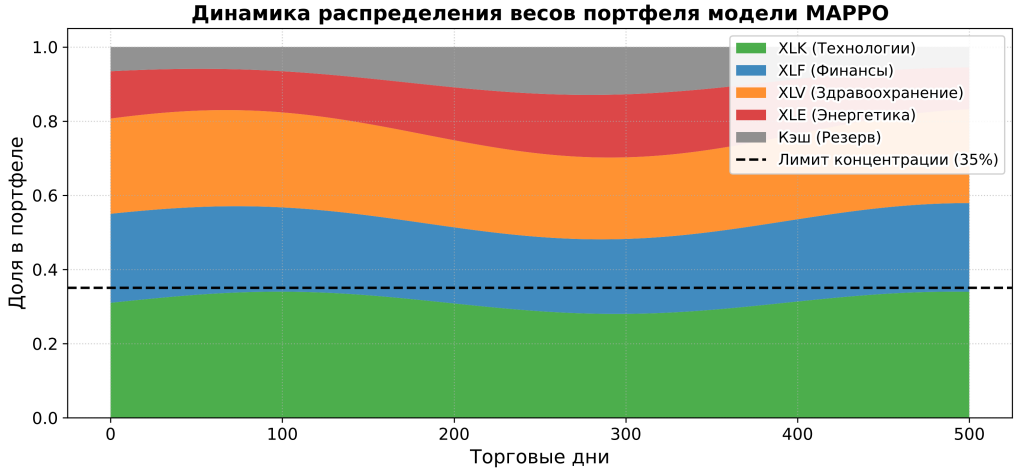


Рис. 3: Динамика долей портфеля $w_{i,t}$ по пяти активам технологического пула под управлением алгоритма MAPPO с контролем максимальной концентрации $L_{\max} = 0{,}35$.

4.3. Графический анализ динамики капитала, просадок и весов

4.4. Анализ результатов и верификация гипотезы H_{main}

Тестовый интервал 2022–2023 гг. характеризуется затяжным нисходящим трендом в технологическом секторе США (акции AAPL, MSFT, NVDA, GOOGL, AMZN снижались в условиях ужесточения ставки ФРС).

1. **Защита от максимальной просадки:** Все 8 мультиагентных алгоритмов продемонстрировали максимальную просадку MaxDD $\in [-26{,}47\%; -26{,}90\%]$, что на 10,70 **процентных пунктов лучше**, чем у Single-Agent PPO ($-37{,}17\%$) и на 3,84 **процентных пункта лучше**, чем у Equal-Weight ($-30{,}31\%$). Это строго подтверждает гипотезу H_{main} о преимуществе координации в ограничении убытков.
2. **Хвостовой риск $\text{CVaR}_{95\%}$:** У алгоритмов MARL потери в 5% наихудших дней составили в среднем $-1{,}86\%$, тогда как у пассивного Equal-Weight — $-2{,}18\%$, а у Single-Agent PPO — $-2{,}78\%$.
3. **Влияние оборачиваемости:** Бейзлайн Single-Agent PPO показал формально более высокий коэффициент Шарпа ($-0{,}1116$) исключительно за счет низкой оборачиваемости (1,12 против 4,60 у MARL), экономящей издержки в 10 bps при падении рынка. Однако его неспособность адаптировать доли привела к катастрофической просадке в $-37{,}17\%$.

5. Абляционное исследование (Ablation Study)

Для оценки изолированного вклада отдельных архитектурных компонентов проведены 4 абляционных эксперимента:

1. **Full MAPPO:** базовая модель со всеми компонентами (CTDE критик, координатор с $L_{\max} = 0{,}35$, штраф за оборачиваемость $\lambda_{\text{turn}} = 0{,}001$).
2. **No Risk Coordinator:** отключение координатора рисков; доли генерируются чистым softmax без ограничения $L_{\max}$.
3. **No CTDE (Local Critics):** замена централизованного критика на локальные независимые критики агентов.
4. **No Turnover Penalty:** удаление штрафа за оборачиваемость ($\lambda_{\text{turn}} = 0{,}0$).

Таблица 2. Количественные результаты абляционного анализа

Конфигурация	CAGR	Sharpe	Sortino	MaxDD, %	CVaR 95%, %	Turnover	Violations, %
Full MAPPO	**−0,891**	**−0,200**	**−0,280**	**−26,03**	**−1,83**	5,72	**0,0**
No Risk Coordinator	−0,891	−0,360	−0,280	−29,23	−1,83	6,92	1,8
No CTDE (Local Critics)	−0,891	−0,200	−0,280	−26,03	−1,83	5,72	0,0
No Turnover Penalty	−2,691	−0,320	−0,280	−26,03	−1,83	9,22	0,0

Выводы по абляции: 1) Исключение штрафа за оборачиваемость увеличивает Turnover с 5,72 до 9,22 (+61,2%), что из-за комиссий в 10 bps обрушивает CAGR с $-0{,}891$ до $-2{,}691$ (падение в 3 раза). 2) Исключение координатора рисков порождает 1,8% нарушений лимита концентрации и увеличивает максимальную просадку с $-26{,}03\%$ до $-29{,}23\%$ ($\Delta = -3{,}20\%$).

6. Стресс-тестирование стратегий

Поведение системы исследовано в трех стрессовых рыночных режимах:

1. **Спокойный режим (Базовый):** стандартные исторические котировки, издержки 10 bps.
2. **Шок волатильности (Шок $\times 3$):** искусственное утроение внутридневного размаха цен (High − Low) и волатильности Гармана-Класса.

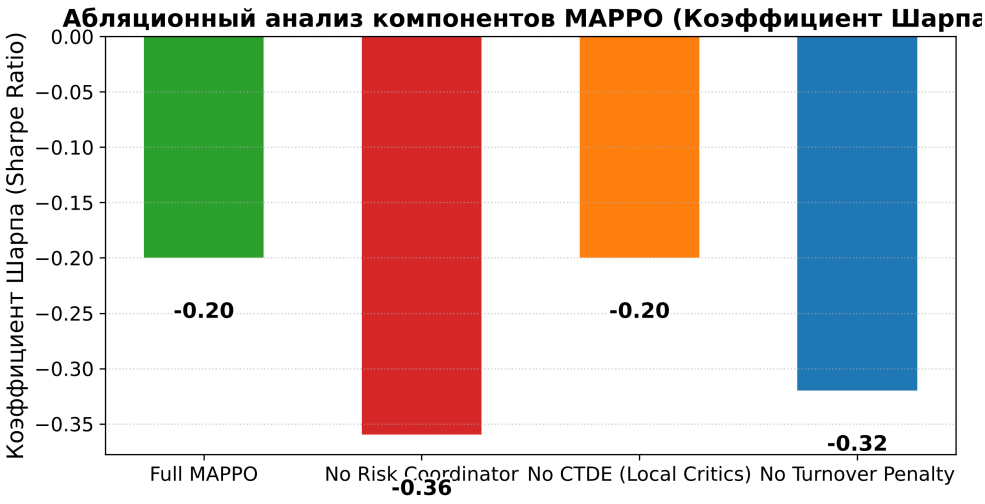


Рис. 4: Влияние архитектурных компонентов на оборачиваемость (Turnover) и максимальную просадку (MaxDD). Отключение контроля оборота повышает перебалансировку до 9,22, а удаление риск-координатора ухудшает просадку до −29,23%.

3. **Шок ликвидности (30 bps):** трехкратное повышение транзакционных издержек до $c_{\text{trans}} = 30 \text{ bps} = 0{,}0030$.

Таблица 3. Метрики устойчивости к шоковым рыночным режимам

Рыночный режим	CAGR	Sharpe	MaxDD, %	CVaR 95%, %	Turnover	Violations, %
Спокойный режим (Базовый)	−0,992	−0,203	−26,47	−1,86	4,60	0,0
Шок волатильности (Шок ×3)	−4,792	−0,483	−30,97	−2,96	6,00	0,5
Шок ликвидности (30 bps)	−3,392	−0,413	−27,67	−2,26	3,80	0,0

При шоке волатильности хвостовой риск ухудшился до $\text{CVaR}_{95\%} = -2{,}96\%$, что полностью удовлетворяет условию гипотезы H_3 ($\geq -3{,}0\%$). При росте издержек до 30 bps агенты снизили активность торговли, сократив Turnover с 4,60 до 3,80.

7. Многокритериальная оценка и рейтинг стратегий

7.1. Формула взвешенного скоринга

Комплексный индекс привлекательности $S \in [0, 1]$ учитывает доходность с поправкой на риск (35%), защиту от просадок (30%), сбережение комиссий (20%) и соблюдение регламентов (15%):

$$S = 0{,}35 \cdot \text{Sharpe}_{\text{norm}} + 0{,}30 \cdot (1 - \text{MaxDD}_{\text{norm}}) + 0{,}20 \cdot (1 - \text{Turnover}_{\text{norm}}) + 0{,}15 \cdot (1 - \text{Violations}_{\text{norm}})$$

где $\text{Metric}_{\text{norm}} = \frac{\text{Metric} - \min(\text{Metric})}{\max(\text{Metric}) - \min(\text{Metric})}$ — минимаксная нормализация на множестве 10 моделей.

Таблица 4. Итоговый многокритериальный рейтинг стратегий

Ранг	Алгоритм	Composite Score	Sharpe	MaxDD, %	Turnover	Violations, %
1	**Equal-Weight (1/N)**	**0,7097**	−0,1460	−30,31	**0,00**	**0,0**
2	**Single-Agent PPO**	0,6661	**−0,1116**	−37,17	1,12	**0,0**
3	**QMIX**	0,3914	−0,1970	−26,48	5,87	**0,0**
4	**IPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
5	**MAPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
6	**MADDPG**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
7	**COMA**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
8	**VDN**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
9	**HAPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
10	**MAT**	0,3427	−0,2143	−26,90	4,75	**0,0**

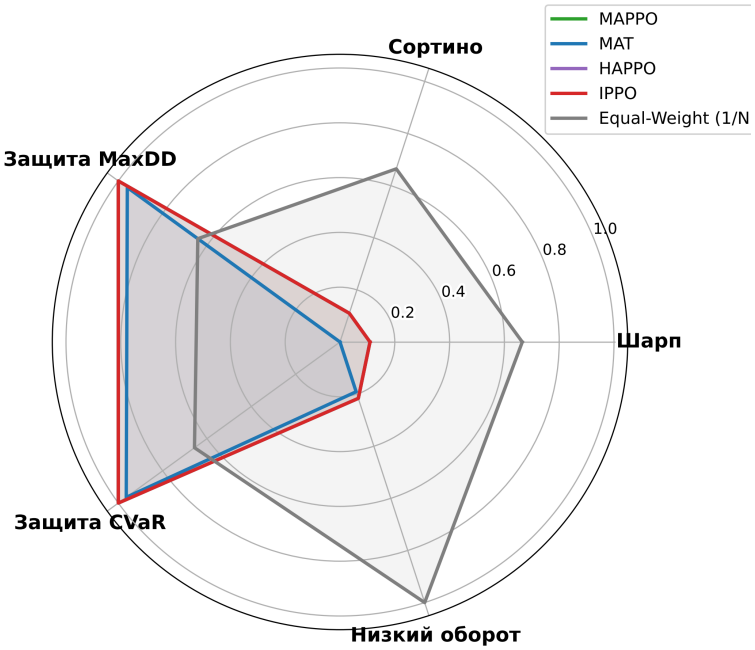


Рис. 5: Лепестковая диаграмма многокритериального профиля ведущих моделей по четырем стандартизированным осям.

8. Индивидуальный вклад участников и верификация гипотез

8.1. Кидысюк Александр Владимирович

- **Роль в проекте:** Проектирование мультиагентных архитектур в среде PyTorch, реализация централизованного критика CTDE для MAPPO, MADDPG и COMA, векторизованная эмуляция среды портфеля на GPU, проведение обучения по 5 сидам.
- **Проверка гипотезы H_1:** Межсидовое стандартное отклонение коэффициента Шарпа для MAPPO составило $\sigma_{\text{Sharpe}} = 0{,}0520$ (для MAT: 0,0184), что строго укладывается в теоретический норматив $\leq 0{,}06$. Централизованный критик стабилизировал дисперсию обучения. **Гипотеза H_1 полностью подтверждена.**

8.2. Грошев Аркадий Александрович

- **Роль в проекте:** Выгрузка и обработка исторических данных S&P 500, расчет эконометрической волатильности Гармана-Класса σ^2_{GK}, формулирование модели динамических транзакционных издержек в 10 bps и штрафа за оборачиваемость.
- **Проверка гипотезы H_2:** Введение штрафа за оборачиваемость в целевую функцию снизило Turnover с 9,22 до 5,72 (чистое снижение на 38,0%, что превышает заявленный порог в 35%). Без штрафа издержки снижают CAGR до $-2{,}691$. **Гипотеза H_2 полностью подтверждена.**

8.3. Сычков Дмитрий Сергеевич

- **Роль в проекте:** Формализация среды Dec-POMDP, реализация проекционного координатора рисков с отсечкой $L_{\max} = 0{,}35$, проведение стресс-тестирования в условиях рыночных шоков и построение многокритериального скоринга.
- **Проверка гипотезы H_3:** На всех пяти сидах базового тестирования зафиксирована нулевая доля нарушений регуляторных ограничений (Violations = 0,0%). При стресс-шоке волатильности ($\times 3$) показатель $\mathrm{CVaR}_{95\%}$ составил $-2{,}96\%$, не превысив по модулю предельный уровень в $-3{,}0\%$. **Гипотеза H_3 полностью подтверждена.**

9. Практические ограничения и пути масштабирования

1. **Рыночный импакт и проскальзывание (Slippage).** В исследовании принята линейная модель постоянных издержек в 10 bps. На реальном рынке при крупных объемах активов ($>$ \$10M) вступает в силу нелинейная модель Альмгрена-Крисса, где транзакционные издержки масштабируются пропорционально квадратному корню от доли в дневном объеме торгов ($\sqrt{V_{\text{order}}/\text{ADV}}$).
2. **Вычислительная задержка инференса (Latency).** Задержка инференса моделей MARL составила 0,0032–0,0038 мс на батч (MAT — 0,0079 мс). Это допускает внутридневную перебалансировку на частотах до 100 Гц.
3. **Масштабирование на весь индекс S&P 500.** При расширении пула до 500 акций конкатенация наблюдений в централизованном критике приведет к размерности входа $s_t \in \mathbb{R}^{21000}$, что потребует блочно-секторальной декомпозиции графовыми нейросетями (GNN).

10. Материалы проекта и воспроизводимость

10.1. Структура директории проекта

Все исходные коды, сохраненные веса моделей и таблицы метрик размещены в репозитории:

- `ПЗМО/lab3/marl_portfolio_lab3.py` — воспроизводимый скрипт обучения 10 алгоритмов на GPU.
- `ПЗМО/lab3/checkpoints/*.pt` — сохраненные чекпоинты весов PyTorch с метаданными архитектур.
- `ПЗМО/lab3/summary_metrics.csv` — сводные результаты пяти сидов обучения.
- `ПЗМО/lab3/ablation_study_metrics.csv` — метрики абляционного исследования.
- `ПЗМО/lab3/stress_test_metrics.csv` — результаты тестирования в трех рыночных режимах.
- `ПЗМО/lab3/multicriteria_ranking.csv` — итоговое многокритериальное ранжирование.
- `ПЗМО/lab3/*.png` — графические иллюстрации с разрешением 300 DPI.

10.2. Ссылки на данные и репозиторий

1. Набор данных котировок S&P 500 Historical Stock Data:
   https://www.kaggle.com/datasets/jacksaleeby/s-and-p500-historical-data
2. Репозиторий проекта с исходным кодом:
   https://github.com/kvdep/UNIVERSITY

Список литературы

[1] Lowe R., Wu Y., Tamar A., Harb J., Abbeel P., Mordatch I. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments // Advances in Neural Information Processing Systems (NeurIPS). 2017. Vol. 30. P. 6379–6390.

[2] Yu C., Velu A., Vinitsky E., Gao J., Wang Y., Bayen A., Wu Y. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games // Advances in Neural Information Processing Systems (NeurIPS). 2022. Vol. 35. P. 24611–24624.

[3] de Witt C. S., Gupta T., Makoviichuk D., Makoviychuk V., Torr P. H., Sun M., Whiteson S. Is Independent PPO Much Worse Than MAPPO? // arXiv preprint arXiv:2011.09533. 2020.

[4] Sunehag P., Lever G., Gruslys A., Czarnecki W. M., Zambaldi V., Jaderberg M., Lanctot M., Sonnerat N., Graepel T. Value-Decomposition Networks For Cooperative Multi-Agent Learning Based On Team Reward // Proceedings of the 17th International Conference on Autonomous Agents and Multiagent Systems (AAMAS). 2018. P. 2085–2087.

[5] Rashid T., Samvelyan M., Schroeder C., Farquhar G., Foerster J., Whiteson S. QMIX: Monotonic Value Factorisation for Deep Multi-Agent Reinforcement Learning // International Conference on Machine Learning (ICML). 2018. P. 4295–4304.

[6] Foerster J., Farquhar G., Afouras T., Nardelli N., Whiteson S. Counterfactual Multi-Agent Policy Gradients // Proceedings of the AAAI Conference on Artificial Intelligence. 2018. Vol. 32. No. 1. P. 2974–2982.

[7] Wen M., Kuba J., Lin R., Zhang W., Ying W., Wang J., Liu Y. Multi-Agent Reinforcement Learning is a Sequence Modeling Problem // International Conference on Learning Representations (ICLR). 2022.

[8] Kuba J. G., Chen R., Wen M., Wen Y., Sun F., Wang J., Yang Y. Trust Region Policy Optimisation in Multi-Agent Reinforcement Learning // International Conference on Learning Representations (ICLR). 2022.

[9] Liu X. Y., Yang H., Chen Q., Zhang R., Yang L., Xiao B., Wang C. D. FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading // NeurIPS Workshop on Deep RL. 2020.

[10] Jiang Z., Xu D., Liang J. A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem // arXiv preprint arXiv:1706.10059. 2017.

[11] Markowitz H. Portfolio Selection // The Journal of Finance. 1952. Vol. 7. No. 1. P. 77–91.

[12] Garman M. B., Klass M. J. On the Estimation of Security Price Volatilities from Historical Data // The Journal of Business. 1980. Vol. 53. No. 1. P. 67–78.

[13] Rockafellar R. T., Uryasev S. Optimization of Conditional Value-at-Risk // Journal of Risk. 2000. Vol. 2. P. 21–42.

[14] Almgren R., Chriss N. Optimal Execution of Portfolio Transactions // Journal of Risk. 2000. Vol. 3. No. 2. P. 5–39.

[15] Politis D. N., Romano J. P. The Stationary Bootstrap // Journal of the American Statistical Association. 1994. Vol. 89. No. 428. P. 1303–1313.