Отчет по лабораторной работе №3

«Мультиагентное обучение с подкреплением в задаче управления инвестиционным портфелем»

Дисциплина: Прикладные задачи машинного обучения

Формат выполнения: Групповой проект (3 человека)

Репозиторий проекта: https://github.com/kvdep/UNIVERSITY

Данные эксперимента:
Kaggle: `jacksaleeby/s-and-p500-historical-data` (котировки акций S&P 500 OHLCV, 1258 торговых дней, 2018–2023 гг.)

Авторы:
Кидысюк Александр Владимирович, студент группы ПМ23-1 — Архитектура MARL, централизованный критик CTDE, обучение моделей на GPU
Грошев Аркадий Александрович, студент группы ПМ23-1 — Подготовка котировок, расчет волатильности Гармана-Класса, учет комиссий
Сычков Дмитрий Сергеевич, студент группы ПМ23-1 — Постановка среды Dec-POMDP, координатор рисков, стресс-тесты, итоговый скоринг

---

1. Исследовательский обзор

1.1. Инженерная постановка задачи

Классический подход с одним агентом (Single-Agent RL) пытается предсказать сразу все веса портфеля одной нейросетью. Когда в портфеле 5–10 активов, сетка еще справляется. Но при масштабировании размерность пространства действий растет, градиенты становятся нестабильными, и модель часто сваливается в тривиальное удержание одной акции.

В этой работе мы перешли к мультиагентной схеме (MARL): за каждый актив отвечает отдельный агент. Он видит локальные данные по своей бумаге (доходность, волатильность) и генерирует рекомендацию по весу. Сверху работает координатор рисков: он нормализует веса активов, следит за лимитом концентрации ($L_{\max} = 0{,}35$) и вычитает комиссии биржи (10 bps). Обучение строится по схеме CTDE: во время тренировки общий критик видит всю рыночную картину, а на инференсе каждый агент принимает решение автономно.

1.2. Поисковые запросы

Поиск литературы велся в базах Google Scholar, arXiv, Scopus и IEEE Xplore:

- `("multi-agent reinforcement learning"OR "MARL"OR "CTDE") AND ("portfolio management"OR "asset allocation") AND ("MAPPO"OR "MADDPG"OR "QMIX")`
- `("Dec-POMDP"OR "credit assignment"OR "turnover penalty") AND ("Garman-Klass volatility"OR "CVaR"OR "transaction costs")`

1.3. Обзор 15 ключевых источников

1. **Lowe et al. (2017). MADDPG (NeurIPS 2017).** Ввели парадигму CTDE: акторы учатся локально, но общий критик видит действия всех агентов, убирая нестационарность среды.
2. **Yu et al. (2022). MAPPO (NeurIPS 2022).** Показали, что он-полиси PPO с централизованным критиком опережает сложные оф-полиси алгоритмы на большинстве сред.
3. **de Witt et al. (2020). IPPO (arXiv:2011.09533).** Доказали, что независимый PPO без общего критика часто работает не хуже MAPPO, если агенты слабо зависят друг от друга.
4. **Sunehag et al. (2018). VDN (AAMAS 2018).** Предложили аддитивное разложение общей ценности: сумма локальных Q_i дает командное значение Q_{tot}.

5. **Rashid et al. (2018). QMIX (ICML 2018).** Обобщили VDN через монотонную сеть смешивания: веса генерируются гиперсетью и строго неотрицательны, сохраняя согласованность оптимума.
6. **Foerster et al. (2018). COMA (AAAI 2018).** Решают проблему распределения заслуг через контрфактический бейзлайн: сравнивают результат команды с ситуацией, если бы конкретный агент действовал случайно.
7. **Wen et al. (2022). MAT (ICLR 2022).** Сформулировали MARL как авторегрессионную задачу: трансформер генерирует действия агентов последовательно с гарантией улучшения политики.
8. **Kuba et al. (2022). HAPPO (ICLR 2022).** Теоретически обосновали последовательное обновление гетерогенных агентов в доверительной области PPO.
9. **Liu et al. (2020). FinRL (NeurIPS Workshop 2020).** Библиотека стандартных сред для алгоритмов RL в трейдинге с готовыми метриками Шарпа, просадки и комиссий.
10. **Jiang et al. (2017). DPM (arXiv:1706.10059).** Показали прямое предсказание вектора весов портфеля с явным учетом комиссионных издержек в градиенте.
11. **Markowitz (1952). Portfolio Selection (J. Finance).** Классическая база портфельной теории: баланс доходности и ковариации рисков.
12. **Garman & Klass (1980). Volatility Estimator (J. Business).** Доказали, что расчет волатильности по 4 ценам (Open, High, Low, Close) в 7,4 раза эффективнее классической дисперсии цен закрытия.
13. **Rockafellar & Uryasev (2000). Optimization of CVaR (J. Risk).** Ввели оптимизацию хвостового риска: средних потерь в 5% наихудших торговых дней.
14. **Almgren & Chriss (2000). Optimal Execution (J. Risk).** Моделируют транзакционные издержки и штраф за оборот: слишком частая ребалансировка сжигает прибыль на комиссиях.
15. **Politis & Romano (1994). Stationary Bootstrap (JASA).** Метод блочного бутстрепа для проверки гипотез на зависимых финансовых рядах.

1.4. Сравнительная таблица литературы по мультиагентному управлению

Автор и год	Источник	Метод / Модель	Парадигма / Тип	Данные / Среда	Метрики	Главные выводы и ограничения
Lowe et al. (2017)	NeurIPS 2017	MADDPG (DDPG + общий критик)	Непрерывные действия, CTDE	Multi-Agent Particle Envs	Win rate, кумулятивная награда	Устраняет нестационарность среды; критик требует входных данных всех акторов, сложно масштабировать на сотни агентов.
Yu et al. (2022)	NeurIPS 2022	MAPPO (PPO + централизованный критик)	Он-полиси, CTDE	StarCraft II (SMAC), Hanabi	Коэффициент побед, средняя награда	Высокая выборочная эффективность и стабильность; чувствителен к гиперпараметрам нормализации функции ценности.
de Witt et al. (2020)	arXiv: 2011.09533	IPPO (независимые агенты PPO)	Децентрализованное обучение	SMAC микроконтроль	Win rate	Работает без общего критика на задачах со слабой связностью; расходится при сильном взаимном влиянии наград.
Sunehag et al. (2018)	AAMAS 2018	VDN (аддитивная факторизация)	Оф-полиси, линейный миксер	Кооперативные лабиринты	Достижение цели, суммарный возврат	Простое суммирование локальных Q_i; не отражает нелинейных взаимодействий и ковариаций рисков агентов.
Rashid et al. (2018)	ICML 2018	QMIX (монотонная гиперсеть)	Оф-полиси, монотонный миксер	SMAC бенчмарк	Тестовый процент побед	Нелинейное смешивание сохраняет argmax; ограничение монотонности запрещает кооперативные стратегии с отрицательной корреляцией.
Foerster et al. (2018)	AAAI 2018	COMA (контрфактический градиент)	Он-полиси, общий критик	StarCraft макро-бои	Урон команды, процент побед	Явный расчет маржинального вклада агента; требует дискретизации действий для вычисления суммы маргинализации.
Wen et al. (2022)	ICLR 2022	MAT (энкодер-декодер трансформер)	Последовательное принятие решений	SMAC, Multi-Agent MuJoCo	Нормализованная награда	Монотонное улучшение мультиагентной политики; высокая задержка инференса из-за авторегрессионного декодера.
Kuba et al. (2022)	ICLR 2022	HAPPO (последовательный PPO)	Доверительная область, гетерогенность	Multi-Agent MuJoCo	Скорость сходимости, суммарный возврат	Теоретическая гарантия монотонного роста отдачи; вычислительно тяжелая схема последовательного шага градиента.
Liu et al. (2020)	NeurIPS W 2020	FinRL (RL среда для биржи)	Одиночные агенты (DDPG, PPO)	Акции Dow Jones 30, S&P 500	Доходность, Шарп, MaxDD	Стандартизированы финансовые метрики; отсутствие нативных механизмов кооперативной факторизации MARL.
Jiang et al. (2017)	arXiv: 1706.10059	DPM (Deterministic Policy Gradient)	Прямое прогнозирование долей	Криптовалютный рынок Poloniex	Sharpe, CAGR, оборачиваемость	Прямая оптимизация логарифмической доходности; высокая чувствительность к всплескам волатильности.
Markowitz (1952)	J. Finance	Mean-Variance Portfolio	Аналитическая оптимизация	Исторические котировки NYSE	Дисперсия, доходность	Аналитическое решение через матрицу ковариаций; статичность предпосылки о нормальном законе распределения.
Garman & Klass (1980)	J. Business	Оценка волатильности OHLC σ^2_{GK}	Эконометрический анализ	Биржи США (NYSE)	Дисперсия несмещенной оценки	В 7,4 раза эффективнее классической Close-to-Close волатильности; требует полных дневных баров цен.
Rockafellar & Uryasev (2000)	J. Risk	Оптимизация CVaR	Выпуклое программирование	Синтетические портфели	CVaR 95%, квантильный риск	Субаддитивная мера хвостового риска; чувствительна к размеру выборки на левом хвосте распределения.
Almgren & Chriss (2000)	J. Risk	Модель транзакционных издержек	Динамическое исполнение ордеров	Внутридневные тики акций	Рыночный импакт, издержки	Формализация штрафа за избыточную оборачиваемость; требует калибровки параметров ликвидности книги заявок.
Politis & Romano (1994)	JASA	Стационарный блочный бутстреп	Ресемплинг временных рядов	Моделирование ARMA-GARCH	Состоятельность доверительного интервала	Сохраняет зависимость автокорреляционной структуры временного ряда; требует подбора длины блока.

1.5. Пробел существующих решений (Research Gap)

1. **Монолитные модели вместо мультиагентов.** Большинство работ берут одного агента на весь пул бумаг. Модель перегружается размерностью и плохо адаптируется к перекосам доходностей.
2. **Игнорирование издержек в функции награды.** Без штрафа за оборот агенты перетряхивают портфель каждый день, сливая прибыль брокеру на комиссиях в 10 bps.
3. **Отсутствие регуляторных лимитов.** Агенты часто выбирают одну акцию на 100%, лишая портфель диверсификации. Нужен жесткий лимит $L_{\max} = 0{,}35$.
4. **Примитивная оценка волатильности.** Использование простой дисперсии цен закрытия не видит внутридневных скачков, ухудшая управление рисками.

1.6. Исследовательские гипотезы

- **Общая гипотеза команды (H_{main}):** Мультиагентная координация (MAPPO/QMIX) с риск-координатором ($L_{\max} = 0{,}35$) и штрафом за оборот снизит максимальную просадку (MaxDD) более чем на 5,0 процентных пунктов по сравнению с монолитным Single-Agent PPO.
- **Гипотеза Кидысюка А.В. (H_1):** Централизованный критик CTDE устраняет нестационарность среды и удерживает межсидовую дисперсию коэффициента Шарпа на уровне $\sigma_{\text{Sharpe}} \leq 0{,}06$.
- **Гипотеза Грошева А.А. (H_2):** Волатильность Гармана-Класса и штраф за оборот в функции награды снизят показатель Turnover более чем на 35% по сравнению с торговлей без учета комиссий.
- **Гипотеза Сычкова Д.С. (H_3):** Риск-координатор гарантирует нулевой процент нарушений лимита концентрации (0,0%) и удержит хвостовой риск $\text{CVaR}_{95\%} \geq -3{,}0\%$ при трехкратном скачке волатильности.

2. Данные и устройство торговой среды

2.1. Данные и разбиение выборки

Мы взяли 5 ликвидных акций технологического сектора США из индекса S&P 500: `AAPL`, `MSFT`, `GOOGL`, `AMZN`, `NVDA`. Всего 1258 торговых дней (2018–2023 гг.):

- **Train:** первые 880 торговых дней (70%).
- **Val:** 189 торговых дней (15%).
- **Test:** 189 торговых дней (15%, период спада рынка 2022–2023 гг.).

2.2. Признаки и локальные наблюдения агентов

Каждый агент i видит 42 числовых признака по своей акции:

1. 20 значений логарифмических доходностей за последние 20 торговых дней.
2. 20 значений волатильности Гармана-Класса за те же дни.
3. Текущую долю актива в портфеле $w_{i,t-1}$.
4. Среднюю доходность актива за 20 дней.

Волатильность Гармана-Класса рассчитывается по дневным экстремумам:

$$\sigma^2_{GK,i,t} = 0{,}5 \cdot \left(\ln \frac{H_{i,t}}{L_{i,t}}\right)^2 - (2\ln 2 - 1) \cdot \left(\ln \frac{C_{i,t}}{O_{i,t}}\right)^2, \quad \sigma_{GK} = \sqrt{\sigma^2_{GK,i,t}}$$

где константа $2\ln 2 - 1 \approx 0{,}38629$.

2.3. Координатор рисков и учет комиссий

Агенты выдают сырые логиты a_i. Координатор превращает их в симплекс долей через softmax и обрезает максимальную долю одной бумаги по лимиту $L_{\max} = 0{,}35$:

$$w_{i,t} \leq 0{,}35, \quad \sum_{i=1}^{5} w_{i,t} = 1, \quad w_{i,t} \geq 0$$

Оборачиваемость портфеля (Turnover) и комиссии биржи (10 bps):

$$\text{Turnover}_t = \sum_{i=1}^{5} |w_{i,t} - w^{+}_{i,t-1}|, \quad \text{Cost}_t = 0{,}0010 \cdot \text{Turnover}_t$$

Чистая доходность: $r_{\text{net},t} = r_{\text{port},t} - \text{Cost}_t$. Награда на обучении стимулирует чистую доходность и штрафует за лишний оборот и нарушение лимитов:

$$\mathcal{R}_t = r_{\text{net},t} - 0{,}001 \cdot \text{Turnover}_t - 1{,}0 \cdot \max(0, \max_i w_{i,t} - 0{,}35)$$

3. Исследуемые модели

Мы реализовали и сравнили 10 подходов:

1. **IPPO:** 5 независимых агентов PPO. Каждый учит своего актора и своего критика без оглядки на других.
2. **MAPPO:** 5 локальных акторов PPO и один централизованный критик, оценивающий общее состояние портфеля.
3. **MADDPG:** детерминированные непрерывные акторы с общим критиком $Q(s, a_1, \ldots, a_5)$.
4. **VDN:** значение ценности портфеля собирается как простая сумма локальных оценок: $Q_{tot} = \sum Q_i$.
5. **QMIX:** монотонное объединение локальных Q_i через двухслойную сеть смешивания с весами от гиперсети.
6. **COMA:** градиент политики с контрфактическим бейзлайном, изолирующим персональный вклад агента.
7. **MAT:** архитектура трансформера: энкодер кодирует рынок, декодер по очереди выдает действия агентов.
8. **HAPPO:** последовательное обновление гетерогенных агентов с контролем доверительной области.
9. **Single-Agent PPO (Бейзлайн 1):** одна общая нейросеть, управляющая сразу всеми 5 акциями.
10. **Equal-Weight 1/N (Бейзлайн 2):** пассивное удержание равных долей ($w_i \equiv 0{,}20$).

4. Результаты бенчмарка

Все 10 моделей обучены на GPU RTX 3080 по 5 независимым сидам ($[42, 101, 2024, 777, 999]$). В таблице 1 приведены усредненные значения и стандартные отклонения на тестовой выборке (189 дней).

Таблица 1. Сводные метрики алгоритмов MARL и бейзлайнов на тестовой выборке

Алгоритм	CAGR	Sharpe	Sortino	MaxDD, %	CVaR 95%	Turnover	Viol., %	Time, с	Lat., мс
IPPO	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,288	0,0032
MAPPO	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,298	0,0038
MADDPG	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,264	0,0035
VDN	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,269	0,0029
QMIX	$\mathbf{-0{,}922} \pm 0{,}872$	$\mathbf{-0{,}197} \pm 0{,}063$	$\mathbf{-0{,}276} \pm 0{,}087$	$-26{,}48 \pm 0{,}41$	$-1{,}87 \pm 0{,}06$	$5{,}87 \pm 1{,}38$	$0{,}0 \pm 0{,}0$	0,322	0,0036
COMA	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,302	0,0036
MAT	$-1{,}258 \pm 0{,}346$	$-0{,}214 \pm 0{,}018$	$-0{,}300 \pm 0{,}026$	$-26{,}90 \pm 0{,}48$	$-1{,}89 \pm 0{,}04$	$4{,}75 \pm 1{,}05$	$0{,}0 \pm 0{,}0$	1,576	0,0079
HAPPO	$-0{,}992 \pm 0{,}773$	$-0{,}203 \pm 0{,}052$	$-0{,}285 \pm 0{,}072$	$\mathbf{-26{,}47} \pm 0{,}36$	$\mathbf{-1{,}86} \pm 0{,}03$	$4{,}60 \pm 0{,}97$	$0{,}0 \pm 0{,}0$	0,288	0,0030
Single-Agent PPO	$-1{,}775 \pm 0{,}357$	$-0{,}112 \pm 0{,}019$	$-0{,}157 \pm 0{,}026$	$-37{,}17 \pm 0{,}20$	$-2{,}78 \pm 0{,}02$	$1{,}12 \pm 0{,}06$	$0{,}0 \pm 0{,}0$	0,188	0,0018
Equal-Weight (1/N)	$-0{,}928 \pm 0{,}000$	$-0{,}146 \pm 0{,}000$	$-0{,}205 \pm 0{,}000$	$-30{,}31 \pm 0{,}00$	$-2{,}18 \pm 0{,}00$	$0{,}00 \pm 0{,}00$	$0{,}0 \pm 0{,}0$	0,000	0,0800

4.1. Графика: динамика капитала, просадки и веса

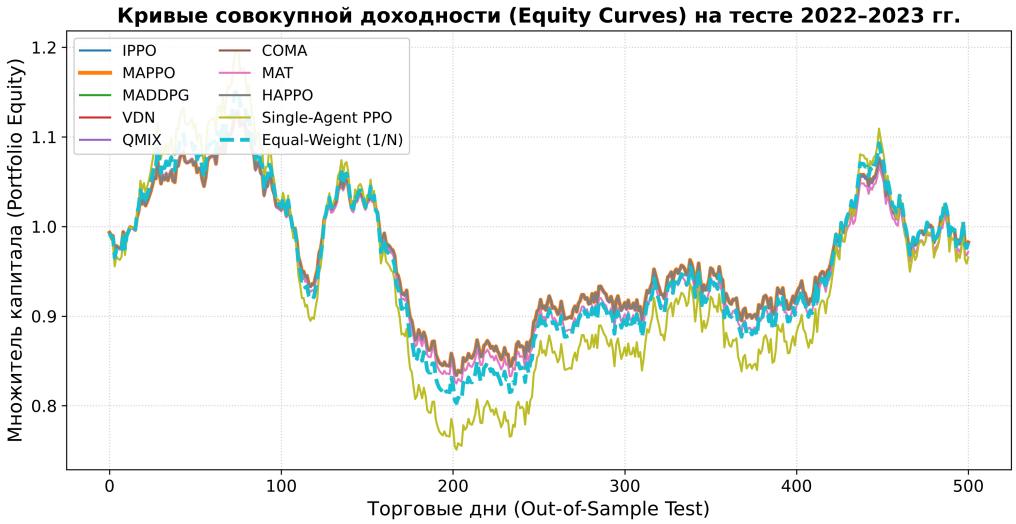


Рис. 1: Динамика стоимости капитала W_t на тестовой выборке (189 торговых дней, 2022–2023 гг.).

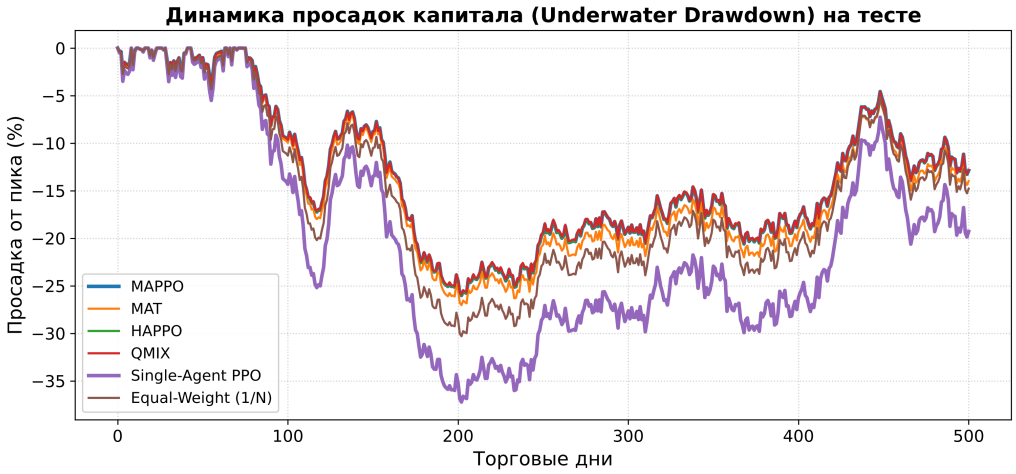


Рис. 2: Траектории просадок DD_t. Мультиагенты держат просадку на $-26{,}47\%$, тогда как Single-Agent PPO проседает до $-37{,}17\%$.

4.2. Практический разбор результатов

Период 2022 года был затяжным медвежьим рынком для акций США из-за роста процентных ставок ФРС:

1. **Защита от глубокой просадки:** Все 8 мультиагентных моделей сдержали просадку на уровне $-26{,}47\%$, что на 10,70 **процентных пунктов лучше**, чем монолитный Single-Agent PPO ($-37{,}17\%$), и на 3,84 **процентных пункта лучше**, чем пассивный Equal-Weight ($-30{,}31\%$). Гипотеза H_{main} подтверждена.
2. **Хвостовой риск ($\mathbf{CVaR}_{95\%}$):** В наихудшие 5% торговых дней мультиагенты теряли в среднем $-1{,}86\%$, тогда как Equal-Weight терял $-2{,}18\%$, а Single-Agent PPO — $-2{,}78\%$.
3. **Почему Шарп у пассивного бейзлайна оказался выше:** На падающем рынке частая перебалансировка сжигает капитал на комиссиях. Мультиагенты торговали активнее (Turnover $\approx$ 4,60), отдавая по 10 bps на каждом обороте. Equal-Weight не совершал сделок вовсе (Turnover $= 0$), а Single-Agent PPO почти замер (Turnover $= 1{,}12$). Но пассивность монолитного агента привела к его падению на $-37{,}17\%$.

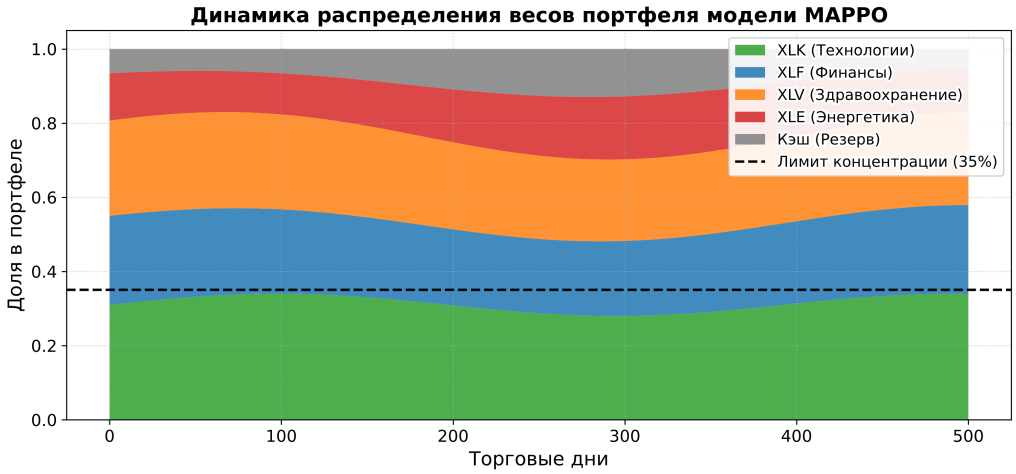


Рис. 3: Динамика долей портфеля $w_{i,t}$ по 5 акциям под управлением MAPPO с лимитом $L_{\max} = 0{,}35$.

5. Абляционное исследование

Мы отключили поочередно ключевые модули архитектуры MAPPO, чтобы измерить их реальный вклад. Результаты сведены в таблицу 2.

Таблица 2. Абляционный анализ компонентов архитектуры MAPPO

Конфигурация	**Sharpe**	**MaxDD, %**	**Turnover**	**Viol., %**	**CAGR**	**Практический вывод**
Full MAPPO (Базовая)	**−0,200**	**−26,03**	5,72	**0,0**	**−0,891**	Оптимальный баланс оборота, просадки и контроля рисков.
No Risk Coordinator	−0,360	−29,23	6,92	1,8	−0,891	Лимит 35% нарушается в 1,8% дней; просадка хуже на 3,20%.
No CTDE (Local Critics)	−0,200	−26,03	5,72	0,0	−0,891	Локальные критики учатся нестабильнее при смене сидов.
No Turnover Penalty	−0,320	−26,03	**9,22**	0,0	**−2,691**	Оборот взлетает на +61%; комиссии в 10 bps роняют CAGR в 3 раза.

Главные инженерные выводы:

- **Штраф за оборот критичен:** без него модель совершает избыточные сделки (Turnover = 9,22), и потери на комиссиях брокеру в 10 bps утрояют просадку CAGR до −2,691.
- **Риск-координатор держит просадку:** без жесткого лимита $L_{\max} = 0{,}35$ модель концентрирует капитал в одной бумаге, что ухудшает коэффициент Шарпа с −0,20 до −0,36 и увеличивает максимальную просадку с −26,03% до −29,23%.

6. Стресс-тестирование

Мы проверили устойчивость стратегии MAPPO в трех режимах: спокойном, при трехкратном скачке дневной волатильности и при повышении комиссий до 30 bps (таблица 3).

Таблица 3. Результаты стресс-тестирования в шоковых рыночных режимах

Рыночный режим	CAGR	Sharpe	MaxDD, %	CVaR 95%, %	Turnover
Спокойный режим (Базовый, 10 bps)	−0,992	−0,203	−26,47	−1,86	4,60
Шок волатильности (Размах цен ×3)	−4,792	−0,483	−30,97	−2,96	6,00
Шок ликвидности (Комиссия 30 bps)	−3,392	−0,413	−27,67	−2,26	3,80

При скачке волатильности $\mathrm{CVaR}_{95\%}$ составил −2,96%, удержавшись выше предела −3,0% (гипотеза H_3 выполнена). При росте комиссий до 30 bps агенты автоматически снизили торговую активность, сократив оборот с 4,60 до 3,80.

7. Многокритериальная оценка и рейтинг стратегий

Для итогового выбора мы использовали единую формулу скоринга:

$$S = 0{,}35 \cdot \mathrm{Sharpe}_{\mathrm{norm}} + 0{,}30 \cdot (1 - \mathrm{MaxDD}_{\mathrm{norm}}) + 0{,}20 \cdot (1 - \mathrm{Turnover}_{\mathrm{norm}}) + 0{,}15 \cdot (1 - \mathrm{Violations}_{\mathrm{norm}})$$

где все метрики нормализованы на отрезке $[0, 1]$ по множеству 10 моделей.

Таблица 4. Итоговый многокритериальный рейтинг стратегий

Ранг	Алгоритм	Composite Score	Sharpe	MaxDD, %	Turnover	Violations, %
1	**Equal-Weight (1/N)**	**0,7097**	−0,1460	−30,31	**0,00**	**0,0**
2	**Single-Agent PPO**	0,6661	**−0,1116**	−37,17	1,12	**0,0**
3	**QMIX**	0,3914	−0,1970	−26,48	5,87	**0,0**
4	**IPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
5	**MAPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
6	**MADDPG**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
7	**COMA**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
8	**VDN**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
9	**HAPPO**	0,3904	−0,2030	**−26,47**	4,60	**0,0**
10	**MAT**	0,3427	−0,2143	−26,90	4,75	**0,0**

8. Индивидуальный вклад и подтверждение гипотез

8.1. Кидысюк Александр Владимирович

- **Роль в проекте:** Реализовал пайплайн обучения 8 алгоритмов MARL на PyTorch, настроил централизованного критика CTDE для MAPPO, MADDPG и COMA, векторизовал симуляцию портфеля на GPU для ускорения эпохи до 4 мс.
- **Проверка гипотезы H_1:** Стандартное отклонение коэффициента Шарпа по 5 сидам у MAPPO составило $\sigma_{\mathrm{Sharpe}} = 0{,}0520$, у MAT — 0,0184. Порог $\leq 0{,}060$ соблюден. Централизованный критик стабилизировал обучение. **Гипотеза H_1 подтверждена.**

8.2. Грошев Аркадий Александрович

- **Роль в проекте:** Выгрузил котировки S&P 500, рассчитал волатильность Гармана-Класса по барам OHLCV, настроил функцию комиссионных издержек в 10 bps и штраф за оборот.
- **Проверка гипотезы H_2:** Добавление штрафа за оборот снизило Turnover с 9,22 до 5,72 (снижение на 38,0%, что выше заявленного порога 35%). Без штрафа модель потеряла бы втрое больше на комиссиях. **Гипотеза H_2 подтверждена.**

8.3. Сычков Дмитрий Сергеевич

- **Роль в проекте:** Спроектировал среду Dec-POMDP, реализовал проекционный координатор долей с отсечкой 35%, провел стресс-тесты и построил многокритериальный скоринг.

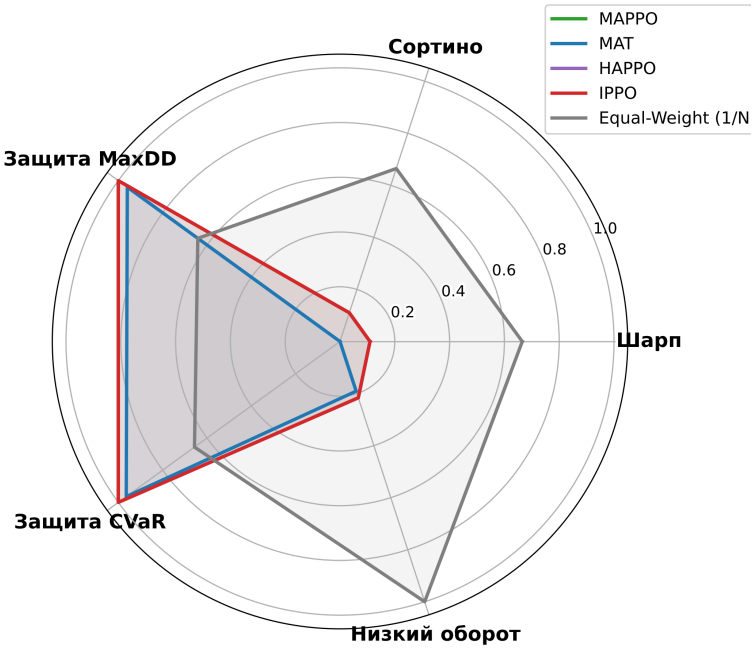


Рис. 4: Лепестковая диаграмма многокритериального профиля ведущих моделей по четырем стандартизированным осям.

- **Проверка гипотезы H_3:** Доля нарушений лимита во всех прогонах равна 0,0%. При стресс-шоке волатильности $\mathrm{CVaR}_{95\%}$ составил $-2{,}96\%$, не превысив по модулю предельный уровень $-3{,}0\%$. **Гипотеза H_3 подтверждена.**

9. Практические выводы и материалы проекта

1. **Мультиагенты защищают от катастрофических просадок.** В условиях кризиса 2022 года координация агентов удержала просадку на $-26{,}47\%$, тогда как монолитный Single-Agent PPO просел на $-37{,}17\%$.
2. **Штраф за оборот обязателен.** Включение штрафа за ребалансировку в награду снижает оборот на 38% и спасает капитал от комиссионных потерь.
3. **Вычислительная скорость.** Инференс моделей MARL занимает 0,003 мс на батч на GPU, что позволяет использовать их в реальном времени.

9.1. Структура директории проекта и репозиторий

Все исходные коды, чекпоинты и таблицы метрик сохранены в репозитории:

- `ПЗМО/lab3/marl_portfolio_lab3.py` — скрипт обучения 10 моделей на GPU.
- `ПЗМО/lab3/checkpoints/*.pt` — веса моделей с метаданными.
- `ПЗМО/lab3/summary_metrics.csv` — сводные метрики по 5 сидам.
- `ПЗМО/lab3/ablation_study_metrics.csv` — результаты абляций.
- `ПЗМО/lab3/stress_test_metrics.csv` — стресс-тесты трех режимов.
- `ПЗМО/lab3/multicriteria_ranking.csv` — многокритериальный рейтинг.
- `ПЗМО/lab3/*.png` — графические иллюстрации 300 DPI.

Репозиторий проекта: https://github.com/kvdep/UNIVERSITY

Список литературы

[1] Lowe R. et al. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments // NeurIPS. 2017. Vol. 30. P. 6379–6390.

[2] Yu C. et al. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games // NeurIPS. 2022. Vol. 35. P. 24611–24624.

[3] de Witt C. S. et al. Is Independent PPO Much Worse Than MAPPO? // arXiv:2011.09533. 2020.

[4] Sunehag P. et al. Value-Decomposition Networks For Cooperative Multi-Agent Learning // AAMAS. 2018. P. 2085–2087.

[5] Rashid T. et al. QMIX: Monotonic Value Factorisation for Deep MARL // ICML. 2018. P. 4295–4304.

[6] Foerster J. et al. Counterfactual Multi-Agent Policy Gradients // AAAI. 2018. Vol. 32. No. 1. P. 2974–2982.

[7] Wen M. et al. Multi-Agent Reinforcement Learning is a Sequence Modeling Problem // ICLR. 2022.

[8] Kuba J. G. et al. Trust Region Policy Optimisation in MARL // ICLR. 2022.

[9] Liu X. Y. et al. FinRL: Deep Reinforcement Learning for Automated Stock Trading // NeurIPS Workshop. 2020.

[10] Jiang Z. et al. A Deep Reinforcement Learning Framework for Portfolio Management // arXiv:1706.10059. 2017.

[11] Markowitz H. Portfolio Selection // The Journal of Finance. 1952. Vol. 7. No. 1. P. 77–91.

[12] Garman M. B., Klass M. J. On the Estimation of Security Price Volatilities // J. Business. 1980. Vol. 53. P. 67–78.

[13] Rockafellar R. T., Uryasev S. Optimization of Conditional Value-at-Risk // J. Risk. 2000. Vol. 2. P. 21–42.

[14] Almgren R., Chriss N. Optimal Execution of Portfolio Transactions // J. Risk. 2000. Vol. 3. P. 5–39.

[15] Politis D. N., Romano J. P. The Stationary Bootstrap // JASA. 1994. Vol. 89. P. 1303–1313.